

초기 총방전 신호로 배터리 수명을 설명하다

세 배치 EDA에서 모델 설계 전략까지

울산 3반 · 신현중

2026년 10월 1일 · ESS 배터리 수명 예측

설계 결정

초기 100사이클에서 총 cycle_life를 예측하는 회귀를 선택합니다. ΔQ 통계·초기 열화·충전·온도 신호를 소수 피처군으로 구성하고 Ridge/Elastic Net부터 검증합니다.

분석 범위: Batch 1·2·3 원본 139셀, 수명 라벨 보유 129셀. 다섯 EDA 질문과 데이터 품질·배치 이동·공선성을 확인했습니다.

주요 발견

B1: 중앙값 858.5, 단수명 0/46(0.0%), 장수명 10/46(21.7%); B2: 중앙값 472.0, 단수명 28/39(71.8%), 장수명 3/39(7.7%); B3: 중앙값 1005.5, 단수명 0/44(0.0%), 장수명 23/44(52.3%).

초기 ΔQ 로그 분산은 B1 수명과 $r=-0.887$ 이며, 유사한 ΔQ 통계량 사이에는 강한 공선성이 확인되었습니다.

550사이클 분류 기준에서 B1: 550 미만 1/46, 550 이상 45/46; B2: 550 미만 30/39, 550 이상 9/39; B3: 550 미만 1/44, 550 이상 43/44. 학습 배치의 클래스 불균형은 회귀 선택의 근거입니다.

DAY 1 모델 설계 문서. DAY 2의 최종 학습·튜닝·테스트 성능은 포함하지 않습니다.

목차 · 요구사항 순서

Question · 핵심 내용(그래프 + 해석) & 시사점

1. Question 1. Cycle Life 분포는 어떻게 생겼는가?
2. Question 2. 열화 곡선 — 방전 용량이 어떻게 감소하는가?
3. Question 3. $\Delta Q(V)$ 곡선 — 초기 사이클에서 차이가 보이는가?
4. Question 4. 충전 조건(C-rate)과 수명의 관계는?
5. Question 5. 상관관계 — 어떤 신호가 수명과 연관되어 있는가?

모델 설계 전략

1. 모델 설계 전략 1. Feature Engineering
2. 모델 설계 전략 2. Regression vs Classification · Target Variable
3. 모델 설계 전략 3. Modeling Strategy

부록 · 자료 검증과 참고

- 부록 A. 데이터 구성·품질과 EOL 주의
- 부록 B. Batch 1·2·3 비교 요약
- 부록 C. ESS 적용 범위와 남은 확인
- 부록 D. 참고자료와 재현 방법


Question 1. Cycle Life 분포는 어떻게 생겼는가?

핵심 답변

배치별 수명 분포가 다릅니다. 중앙값은 B1 858.5, B2 472.0, B3 1,005.5사이클입니다. 단수명 비율은 0.0% / 71.8% / 0.0%, 장수명 비율은 21.7% / 7.7% / 52.3%입니다. 극단 수명 셀의 정책과 종료 용량은 확인했지만 짧은 수명의 원인은 확정하지 않았습니다.

- 확인 항목**
- 150–2,300사이클 Histogram
 - 장수명(>1,000) / 단수명(<500) 비율
 - 극단 수명 셀 식별과 짧은 수명의 원인 검토

핵심 내용 · 그래프와 해석



배치별 수명 분포: 동일 구간 히스토그램과 셀 단위 박스플롯. 150–2,300 밖의 관측치는 없습니다.

배치	셀 수	평균	표준편차	최솟값	25%	중앙값	75%	최댓값
B1	46.000	844.717	184.629	534.000	703.250	858.500	914.250	1227.000
B2	39.000	565.744	222.202	392.000	439.500	472.000	508.500	1186.000
B3	44.000	1059.659	313.870	541.000	828.000	1005.500	1155.250	1935.000

배치	유효 n	<500 셀	>1000 셀	<550 셀	≥550 셀	500-1000 셀	<500 (%)	>1000 (%)	<550 (%)
B1	46	0	10	1	45	36	0.000	21.739	2.174
B2	39	28	3	30	9	8	71.795	7.692	76.923
B3	44	0	23	1	43	21	0.000	52.273	2.273

관찰: B1: 중앙값 858.5, 단수명 0/46(0.0%), 장수명 10/46(21.7%); B2: 중앙값 472.0, 단수명 28/39(71.8%), 장수명 3/39(7.7%); B3: 중앙값 1005.5, 단수명 0/44(0.0%), 장수명 23/44(52.3%).

해석: 배치 이동 시 타깃 분포가 달라집니다. 단순히 동일 분포의 새 표본으로 가정할 수 없습니다. 극단 수명 셀은 삭제하지 않고 아래의 정책·용량 종료 상태를 확인합니다. 짧은 수명 자체는 측정 오류의 근거가 아닙니다.

셀 ID	총 수명	충전 정책	초기 QD (Ah)	종료/초기 QD
B1c20	534.000	5.4C(80%)-5.4C	1.075	0.822
B2c19	392.000	6C(60%)-3C	1.093	0.762
B3c28	541.000	3.7C(31%)-5.9C-newstructure	1.053	0.838
B1c4	1227.000	4C(80%)-4C	1.081	0.946
B2c34	1186.000	5.6C(26%)-4.5C-newstructure	1.068	0.775
B3c38	1935.000	5C(67%)-4C-newstructure	1.072	0.822

전략: 수명 구간별 잔차·MAPE를 DAY 2에서 따로 확인합니다. 550 분류 기준은 Batch 1에 단수명 표본이 거의 없어 안정적인 학습·검증이 어렵습니다. 총 수명을 연속값으로 예측하는 회귀를 우선 검토합니다.

시사점 · 모델 설계 연결

타깃 분포 이동을 전제로 배치별 평가와 수명 구간별 잔차 분석을 계획합니다. B1에 550 미만 셀이 1개뿐이므로 회귀를 선택합니다. 짧은 수명 셀을 오류로 간주해 삭제하지 않고 셀별 원인은 후속 확인합니다.

Question 2. 열화 곡선 — 방전 용량이 어떻게 감소하는가?

핵심 답변


용량 감소는 셀마다 다르며, 후기 기울기가 더 가파른 가속 열화 후보가 확인됩니다. 설명용 knee 후보는 B1 45/46, B2 39/39, B3 44/44셀이고, 후보의 중앙 시작점은 각각 607, 356, 818.5사이클입니다. 제공 수명 라벨과 초기 용량 대비 80% 기준은 구분합니다.

확인 항목

- 사이클별 Qd 추이
- 일정한 열화와 가속 열화 비교
- Knee point 탐색

핵심 내용 · 그래프와 해석

Q2 · 열화 속도는 일정한가?



상단: 방전 용량. 하단: 초기 기준으로 정규화. 색상은 실제 수명이며, 80% 아래 말기 구간도 유지합니다.

배치	유효 n	knee 후보 수	knee 중앙 사이클	SSE 개선 중앙값
B1	46	45	607.000	0.968
B2	39	39	356.000	0.941
B3	44	44	818.500	0.952

배치	유효 n	종료비율>80% 셀	종료비율 중앙값	초기 QD 중앙값(Ah)
B1	46	46	0.819	1.081
B2	39	0	0.759	1.097
B3	44	44	0.826	1.068


수치 요약: knee 후보는 B1 45/46, B2 39/39, B3 44/44에서 검출됐습니다. 후보 위치 중앙값은 각각 607, 356, 818.5사이클입니다. 종료 용량 비율 중앙값은 B1 81.9%, B2 75.9%, B3 82.6%로, 동일한 관측 초기 기준 EOL로 해석할 수 없습니다.

관찰: 곡선은 초기 용량 수준이 비슷해도 이후 경로와 종료 시점이 다릅니다. 정규화 곡선의 80% 도달 여부와 제공 라벨은 반드시 일치하지 않습니다. 위 종료 비율은 마지막 5개 QD의 중앙값/초기 기준입니다.

방법: 비정상 QD를 제외하고 11점 이동 중앙값, 5사이클 간격으로 완화합니다. 기록의 15~85% 구간에서 연속 2구간 직선의 SSE를 최소화합니다. 단일 직선보다 SSE가 25% 이상 감소하고 후기 기울기가 음수이며 절댓값이 초기의 1.5배 이상일 때 knee 후보로 표시합니다. 임계값은 탐색용이며 물리적인 확정 시점이 아닙니다.

전략: 예측 입력은 10~100사이클의 QD 기울기·변동성을 후보로 삼습니다. 전체 기록의 knee, 종료 비율, 전체 기록 길이는 미래 정보여서 입력에서 제외합니다. 라벨의 명목용량 기준 및 Batch 1 미완주 가능성을 먼저 확인합니다.

Q2 보충 · 대표 셀과 변화점의 한계



배치별 최소·최대 수명 셀의 정규화 용량. 점선 수직선은 방법에 의해 검출된 knee 후보이며 수명 그룹 전체를 대표하는 통계는 아닙니다.

극단 셀의 종료 상태와 곡선을 대조했습니다. Batch 1의 긴 수명 셀은 관측 종료에도 80% 위에 남을 수 있어 장수명을 온전히 관측했는지 검증이 필요합니다. 측정값만으로 짧은 수명의 물리적 원인을 확인할 수 없습니다. 점선은 탐색 알고리즘이 선택한 후보이며 단일 knee 정의나 실사용 임계값을 주장하지 않습니다.

시사점 · 모델 설계 연결

초기 100사이클의 QD 기울기를 피쳐 후보로 삼습니다. 전체 기록으로 찾은 knee와 종료 용량은 미래 정보이므로 모델 입력에서 제외합니다.

Question 3. $\Delta Q(V)$ 곡선 — 초기 사이클에서 차이가 보이는가?


핵심 답변

초기 사이클 10·100의 $\Delta Q(V)$ 에는 수명과 연관된 신호가 있습니다. ΔQ 로그 분산과 수명의 Pearson 상관은 B1 -0.887, B2 -0.901, B3 -0.700입니다. B1·B3에는 <500사이클 셀이 없어 해당 단수명 집단 비교는 산출하지 않는다.

- 확인 항목**
- $Q_{100}(V) - Q_{10}(V)$ 계산
 - 장수명 / 단수명 ΔQ 형태 비교
 - 구분 가능한 통계 피쳐 추출

핵심 내용 · 그래프와 해석

Q3 · 초기 곡선의 작은 차이를 수명 신호로 쓸 수 있는가?



그룹별 ΔQ 중앙값과 사분위 범위. 상단은 원본 Qdlin을 공통 전압에 보간, 하단은 3.4V의 용량 차이를 제거한 민감도 점검. B1·B3에는 <500 셀이 없습니다.

배치	신호	수명 상관관계
B1	log10 Var ΔQ	Pearson $r=-0.887$, Spearman $\rho=-0.872$, $n=46$
B2	log10 Var ΔQ	Pearson $r=-0.901$, Spearman $\rho=-0.700$, $n=39$
B3	log10 Var ΔQ	Pearson $r=-0.700$, Spearman $\rho=-0.784$, $n=44$

배치	유효 n	raw 전압범위 확보	3.4V ΔQ 중앙값(Ah)	raw RMSE 중앙값(Ah)
B1	46	46	-7.61e-05	3.03e-04
B2	39	39	-9.90e-05	3.01e-04
B3	44	44	3.28e-05	2.86e-04

수치 요약: ΔQ 로그 분산의 수명 Pearson r은 B1 -0.887, B2 -0.901, B3 -0.700입니다. B1에서 원본 보간값과 raw 재보간값의 수명 관계가 비슷하지만, B2 일부 셀의 raw Qd에는 저전압 방전 중 0으로 떨어지는 표본이 있어 재보간을 왜곡합니다. 아래는 RMSE가 큰 셀의 점검 기록입니다.


셀 ID	배치	3.4V ΔQ(Ah)	raw 전압범위 확보	raw RMSE(Ah)	저전압 Qd≤0 표본
B2c41	B2	-1.52e-04	True	0.386	61
B2c46	B2	1.45e-04	True	0.373	63
B2c42	B2	-2.01e-04	True	0.360	63
B2c45	B2	2.93e-05	True	0.309	77
B2c44	B2	-6.94e-05	True	0.294	74
B2c43	B2	1.19e-04	True	0.270	76

관찰: 초기 100-10사이클 ΔQ 형태와 통계량을 확인했습니다. 수명 그룹이 없는 배치는 해당 비교를 생략했고, 중간 그룹을 단수명으로 이름 바꾸지 않았습니다. 색별 띠는 표본의 IQR이며 신뢰구간이 아닙니다.

정렬 검증: 모든 Vdlin 축은 동일합니다. 하지만 동일 축이 동일 용량 원점·측정 절차를 뜻하지는 않습니다. 공통 2.1-3.4V에서 raw 방전 구간($I < -0.1A$)을 재보간해 Qdlin ΔQ와 RMSE를 비교했습니다. raw가 해당 구간 전체를 덮지 못하는 셀은 외삽하지 않았습니다. 원점 정렬은 3.4V에서 ΔQ를 빼는 민감도 비교이며 모든 구조 차이를 해결했다고 주장하지 않습니다. raw 비교의 중앙 RMSE만으로 모든 셀이 정합하다고 결론 내리지 않습니다. B2c41-46의 큰 RMSE와 0값 문제를 기록했으며 raw 재보간 피쳐는 품질 진단용으로만 사용합니다.

피쳐: $\log_{10}(\text{var}(\Delta Q))$, 최소값, 평균, 범위를 검토합니다. 분산은 공통 500점의 모집단 분산($\text{ddof}=0$), 단위 Ah^2 이며 0 또는 비유한값은 NaN으로 처리합니다. 상수 원점 이동은 분산을 바꾸지 않지만 평균·최솟값은 바꿉니다. 분산 피쳐를 우선 후보로 두고 평균·최솟값은 중복 및 측정 정렬을 확인한 뒤 채택합니다.

Q3 보충 · ΔQ 통계량과 수명 관계



배치별 ΔQ 로그 분산과 수명 관계. 원본 셀당 한 점이며, 선형·순위 상관을 함께 표시합니다.

관계의 크기는 배치별로 확인해야 합니다. B1에서 raw와 Qdlin 로그 분산 r은 각각 -0.888·-0.887로 유사하지만, B2 raw 재보간은 저전압 0값 때문에 왜곡됩니다. 원본 전체 전압 구간, 공통 구간, raw 재보간 분산의 차이는 아래 상관관계 표에서 검토합니다.

이 그림의 Batch 2·3 수명 상관을 기준으로 학습 피처를 최적화하지 않습니다. DAY 2 선정은 Batch 1 학습 fold 안에서 재검증합니다.

시사점 · 모델 설계 연결

ΔQ 로그 분산을 우선 피처로 선정합니다. 최소·평균·범위는 중복과 오프셋 민감도를 검토해 추가하며, raw 재보간 정합성 문제가 있는 신호는 진단용으로 제한합니다.

Question 4. 충전 조건(C-rate)과 수명의 관계는?

핵심 답변


고속 충전이면 항상 수명이 짧다고 단정할 수 없습니다. 첫 충전 C-rate(C1)와 수명의 상관은 B1 -0.580, B2 +0.191, B3 -0.083으로 배치마다 다릅니다. 충전 전류와 초기 QD 기울기의 상관도 +0.357 / -0.433 / -0.080으로 일관되지 않습니다.

확인 항목

- 충전 프로토콜별 평균 수명
- 고속 충전과 단수명의 관계
- 충전 전류 패턴과 열화 속도의 상관


핵심 내용 · 그래프와 해석

Q4 · 고속 충전이면 언제나 수명이 짧은가?




B1: 정책별 평균 ±1표준편차와 개별 셀. n=1은 표준편차를 추정할 수 없어 오차막대 없이 표시합니다. newstructure 접미사는 보존합니다.

B2: policy mean $\pm$ 1 SD, individual cells



B2: 정책별 평균 $\pm$ 1표준편차와 개별 셀. n=1은 표준편차를 추정할 수 없어 오차막대 없이 표시합니다. newstructure 접미사는 보존합니다.

B3: policy mean $\pm$ 1 SD, individual cells



B3: 정책별 평균 $\pm$ 1표준편차와 개별 셀. n=1은 표준편차를 추정할 수 없어 오차막대 없이 표시합니다. newstructure 접미사는 보존합니다.

수치 요약: C1-수명 r은 B1 -0.580, B2 +0.191, B3 -0.083입니다. 초기 충전시간-수명 r은 +0.577, +0.087, +0.637입니다. 따라서 B1의 관계를 모든 배치의 동일한 충전 효과로 일반화할 수 없습니다.


관찰: 동일 명목 C-rate라도 전환 SOC, 두 번째 단계, newstructure 조건에 따라 수명이 다릅니다. 정책별 표본 수와 분포를 함께 보아야 하며 전체 C1만으로 충전 강도를 대표하기 어렵습니다.

수명 라벨이 있는 셀의 정책 분해 실패: 0개. 접미사는 원문 정책에 유지하고 newstructure를 별도 표식으로 저장했습니다.

해석: 빠른 충전의 영향을 관찰할 수 있지만 정책과 구조·배치·온도 등이 함께 변합니다. 충전 속도 자체의 인과효과나 구조 변경의 효과를 확정하지 않습니다.

전략: C1·SOC·C2를 수치 피쳐 후보로 분해해 미관측 정책에도 적용 가능하게 합니다. 정책 문자열은 보조 범주형 후보로 남기며 구조 접미사를 삭제해 서로 다른 실험을 합치지 않습니다. 구조 표식은 Batch 1에 변화가 없으면 학습 입력에서 제외하고 도메인 이동 점검에 사용됩니다.

Q4 보충 · 충전 신호와 초기 열화 속도



10사이클 양수 전류($I > 0.1A$) 중앙값과 10-100사이클 QD 기울기. 전체 충전 프로토콜의 시간 가중 평균은 아니며 설명용 요약값입니다.

배치	피쳐	수명 상관관계
B1	C1	Pearson $r=-0.580$, Spearman $\rho=-0.483$, $n=46$
B1	C2	Pearson $r=-0.096$, Spearman $\rho=0.047$, $n=46$
B1	switch_SOC	Pearson $r=0.235$, Spearman $\rho=0.185$, $n=46$
B1	mean_chargetime	Pearson $r=0.577$, Spearman $\rho=0.613$, $n=46$
B1	I10_charge_median	Pearson $r=0.351$, Spearman $\rho=0.297$, $n=46$
B2	C1	Pearson $r=0.191$, Spearman $\rho=0.055$, $n=39$
B2	C2	Pearson $r=-0.116$, Spearman $\rho=-0.119$, $n=39$
B2	switch_SOC	Pearson $r=0.116$, Spearman $\rho=0.288$, $n=39$
B2	mean_chargetime	Pearson $r=0.087$, Spearman $\rho=-0.393$, $n=39$
B2	I10_charge_median	Pearson $r=0.233$, Spearman $\rho=-0.104$, $n=39$
B3	C1	Pearson $r=-0.083$, Spearman $\rho=-0.229$, $n=44$
B3	C2	Pearson $r=-0.043$, Spearman $\rho=0.016$, $n=44$
B3	switch_SOC	Pearson $r=0.541$, Spearman $\rho=0.443$, $n=44$
B3	mean_chargetime	Pearson $r=0.637$, Spearman $\rho=0.192$, $n=44$
B3	I10_charge_median	Pearson $r=0.456$, Spearman $\rho=0.501$, $n=44$
배치	신호	초기 QD 기울기 상관
B1	I10_charge_median	Pearson $r=0.357$, Spearman $\rho=0.282$, $n=46$
B1	mean_chargetime	Pearson $r=0.566$, Spearman $\rho=0.598$, $n=46$
B2	I10_charge_median	Pearson $r=-0.433$, Spearman $\rho=-0.442$, $n=39$
B2	mean_chargetime	Pearson $r=-0.231$, Spearman $\rho=-0.187$, $n=39$
B3	I10_charge_median	Pearson $r=-0.080$, Spearman $\rho=-0.136$, $n=44$
B3	mean_chargetime	Pearson $r=0.122$, Spearman $\rho=-0.104$, $n=44$

전류의 양수 표본 중앙값은 충전 패턴의 일부만 요약합니다. 초기 충전시간과 함께 확인하지만, 샘플링 간격과 단계별 지속시간 차이가 납니다. 낮은 상관도 인과관계의 부재를 의미하지 않습니다. 이 신호와 C-rate·충전시간 사이의 중복은 다음 피쳐 상관행렬에

서 점검합니다.

시사점 · 모델 설계 연결

C1·전환 SOC·C2와 초기 충전시간을 후보로 구성하되 중복 피처를 비교합니다. 정책별 표본 수·구조 차이를 확인하고 충전 조건의 인과효과를 단정하지 않습니다.

Question 5. 상관관계 — 어떤 신호가 수명과 연관되어 있는가?


핵심 답변

학습 배치 B1에서 ΔQ 로그 분산은 수명과 강한 음의 관계를 보인다(Pearson -0.887 , Spearman -0.872). 다만 ΔQ 최소·평균·범위와 로그 분산이 중복 정보를 담으며, 온도·충전시간의 관계는 배치에 따라 달라집니다. 전체 상관을 배치 내 관계와 함께 해석합니다.

- 확인 항목**
- 초기 피처와 Cycle Life 상관계수
 - 가장 강한 관계 식별
 - 다중공선성 확인

핵심 내용 · 그래프와 해석

Q5 · 어떤 신호를 우선 후보로 둘 것인가?



피처-수명 Pearson·Spearman 상관. 피처 순서는 Batch 1의 Pearson 절댓값 순이며 배치별 관계를 별도로 표시합니다. 결측·상수 피처는 산출 불가.

피처	All	B1	B2	B3
delta_raw_logvar	-0.528	-0.888	0.011	-0.706
delta_logvar	-0.849	-0.887	-0.901	-0.700
delta_full_logvar	-0.851	-0.886	-0.902	-0.702
delta_min	0.827	0.882	0.818	0.692
delta_range	-0.800	-0.882	-0.802	-0.602
delta_mean	0.803	0.858	0.778	0.647

피처	All	B1	B2	B3
delta_anchor_mean	0.802	0.858	0.777	0.644
C1	-0.078	-0.580	0.191	-0.083
mean_chargetime	-0.194	0.577	0.087	0.637
QD_slope_10_100	-0.132	0.524	-0.484	0.361
mean_Tavg	0.239	-0.482	0.425	-0.022
mean_Tmax	-0.017	-0.404	0.019	-0.106
l10_charge_median	0.500	0.351	0.233	0.456
std_QD	-0.331	-0.243	0.173	-0.343
switch_SOC	0.222	0.235	0.116	0.541
mean_IR	-0.336	0.218	-0.626	0.190
mean_QD	-0.497	0.205	-0.333	0.218
IR_change	0.077	0.131	0.169	-0.396
C2	-0.125	-0.096	-0.116	-0.043
initial_QD	-0.516	0.088	-0.263	0.150

피처	유효 n	Pearson	Spearman
delta_raw_logvar	46	-0.888	-0.872
delta_logvar	46	-0.887	-0.872
delta_full_logvar	46	-0.886	-0.871
delta_min	46	0.882	0.853
delta_range	46	-0.882	-0.850
delta_mean	46	0.858	0.830
delta_anchor_mean	46	0.858	0.824
C1	46	-0.580	-0.483
mean_chargetime	46	0.577	0.613
QD_slope_10_100	46	0.524	0.578
mean_Tavg	46	-0.482	-0.371
mean_Tmax	46	-0.404	-0.323
l10_charge_median	46	0.351	0.297
std_QD	46	-0.243	0.031
switch_SOC	46	0.235	0.185
mean_IR	46	0.218	0.189
mean_QD	46	0.205	0.226
IR_change	46	0.131	-0.233
C2	46	-0.096	0.047
initial_QD	46	0.088	0.092


배치	delta_logvar	mean_IR	IR_change	mean_Tavg	mean_chargetime
B1	46	46	46	46	46
B2	39	33	33	39	39
B3	44	44	44	44	44

핵심 발견: 온도 평균-수명 r은 B1 -0.482, B2 +0.425, B3 -0.022인데 전체에서는 +0.239입니다. 충전시간도 B1 +0.577·B3 +0.637과 전체 -0.194가 다릅니다. 배치가 섞인 상관으로 물리적 원인을 단정하지 않습니다. ΔQ 원본 로그 분산은 세 배치에서 음의 관계를 보이지만 raw 재보간은 B2의 0값 오류 때문에 r=+0.011로 왜곡됩니다. 이 진단 피처를 학습 후보로 채택하지 않습니다.

관찰: 각 초기 신호의 관계 크기와 방향은 배치마다 다를 수 있습니다. All 열은 배치 차이가 섞인 결과라 배치 내 관계를 대체하지 않습니다. 유효 n은 결측 제거 후 셀 수입니다.

전략: ΔQ 로그 분산·초기 용량 변동/기울기·충전 및 온도 신호를 소수의 피처군으로 검토합니다. Batch 1에서 검증하고, 단순 평균 IR처럼 약한 선형 신호도 변화율이나 비선형 관계를 확인한 뒤 판단합니다. 상관계수만으로 최종 피처 또는 성능을 확정하지 않습니다.

Q5 보충 · 파생변수의 중복을 어떻게 줄일 것인가?



Batch 1 초기 피처 간 상관행렬. $|r| \geq 0.85$ 인 쌍을 아래 표로 별도 표시하고 중복 피처·규제 전략을 수립합니다.

피쳐 1	피쳐 2	r	유효 n
delta_min	delta_range	-1.000	46
delta_mean	delta_range	-0.994	46
delta_min	delta_mean	0.994	46
initial_QD	mean_QD	0.981	46
mean_Tavg	mean_Tmax	0.956	46
delta_logvar	delta_min	-0.946	46
delta_logvar	delta_range	0.946	46
delta_logvar	delta_mean	-0.928	46
C1	switch_SOC	-0.854	46

수치 근거: B1의 ΔQ 최소-범위 $r=-0.999966$, 평균-범위 $r=-0.993615$ 로 거의 같은 정보를 담습니다. 온도 평균-최대 $r=0.955804$, 초기 QD 기준-평균 $r=0.980642$ 입니다. 각 군의 대표값부터 투입하고 나머지는 제거 비교로 검증합니다.

전략: ΔQ 분산·범위·최솟값·평균을 모두 자동 투입하지 않습니다. 각 군에서 해석 가능하고 원점 변화에 강한 대표 피처를 우선합니다. 온도 평균/최댓값, 초기 QD 수준, 충전시간/정책/전류도 같은 정보를 중복할 수 있습니다. $|r| \geq 0.85$ 는 탐색 기준이며 최종 제거는 학습 fold 안에서 수행합니다.

Ridge는 잔존 공선성에 규제를 적용하고 Elastic Net은 선택·규제를 함께 검토합니다. 트리 모델에서도 중복 피처를 그대로 늘려 중요도를 과해석하지 않습니다. 최종 설계 행렬에서 조건수 또는 VIF를 추가 확인하되 n 대비 피처 수를 먼저 줄입니다.

시사점 · 모델 설계 연결

B1 내 상관을 피처 선별 근거로 사용합니다. 공선성이 높은 피처군을 축소하고 Ridge/Elastic Net 규제를 비교합니다. 선택·대치·스케일링은 학습 fold 안에서만 수행합니다.

모델 설계 전략 1. Feature Engineering

선별 원칙

Q3·Q5의 ΔQ 관계를 우선 반영하고, Q2의 초기 열화 기울기와 Q4의 충전 조건을 후보로 추가합니다. 강한 공선성과 배치별 관계 변화는 피쳐 축소·검증에 반영합니다.

피쳐군	계산/정의	관측 기간	객관적 근거	채택 계획	전처리·공선성
ΔQ 로그 분산	$\log_{10}(\text{var}(Q_{100}-Q_{10})); 2.1-3.4V, 500\text{점}$	10·100	B1 $r=-0.887, \rho=-0.872, n=46$	우선 후보: 원점 이동에 불변	0분산/비유한→NaN; 대치·스케일 fold 내부
초기 QD 기울기	$\text{polyfit}(\text{cycle}, QD, 1)$ 의 기울기	10-100	B1 $r=0.524, \rho=0.578, n=46$	후보: 초기 열화 방향·속도	QD 비정상값 제외; std_QD와 중복 비교
초기 QD 변동성	QD 표본 표준편차($\text{ddof}=1$)	2-100	B1 $r=-0.243, \rho=0.031, n=46$	보조 후보: 순위 상관이 약해 우선순위 낮음	단일 스파이크 민감도 및 강건 통계 비교
초기 충전시간	양수 <code>chargetime</code> 평균	2-100	B1 $r=0.577, \rho=0.613, n=46$	후보: 충전 과정 요약	C1/C2/전류와 중복; 단위 원문 메타데이터 확인
온도 대표값	<code>Tavg</code> 평균; <code>Tmax</code> 대체 비교	2-100	B1 $r=-0.482, \rho=-0.371, n=46$	대표값 하나부터 비교	평균·최대 중복 시 축소; 변화량은 후속 확인
정책 수치 분해	C1, 전환 SOC(%), C2	실험 시작 시	B1 $r=-0.580, \rho=-0.483, n=46$	후보: 미관측 정책에 수치적 대응	정책 파상·단위 검증; fold 내부 스케일링
IR 평균/변화	$IR>0$ 평균; $\text{median}(IR_{91:100})-\text{median}(IR_{2:10})$	≤ 100	B1 $r=0.218, \rho=0.189, n=46$	보조 후보: ΔIR와 제거 비교	0값은 미측정 가능성; 실제 기록 확인 후 대치
ΔQ 최소·평균·범위	$\min/\text{mean}/\text{ptp}(\Delta Q)$	10·100	B1 $r=0.882, \rho=0.853, n=46$	보류: 공선성·원점 민감도	로그 분산과 군별 제거 비교
정책 문자열	<code>policy_readable</code> 원문	실험 시작 시	정책별 n-분포 및 미관측 정책	보조 비교: One-hot/CatBoost	미관측 범주 지원; 접미사 보존
ID·배치·knee·전체 길이·종료 비율	설명용 메타데이터	미래 정보 포함	Q1·Q2 품질 및 분포	입력 제외	분할 관리와 오류 분석에만 사용
<code>newstructure</code>	정책 접미사 표식	실험 시작 시	B1 내 구조 변화 유무	B1에서 상수이면 입력 제외	배치 이동 설명에 사용; 데이터 수집 확장 필요

피쳐 구성 순서

- ΔQ 로그 분산 단일 피쳐를 기준으로 시작한다(Q3·Q5).
- QD 기울기, 충전시간, 온도 대표값, 정책 수치를 피쳐군 단위로 추가·제거한다(Q2·Q4·Q5).
- ΔQ 최소·평균·범위는 중복 검토 후 채택합니다. ID·배치·knee·전체 기록 길이·종료 비율은 입력에서 제외합니다.

모델 설계 전략 2. Regression vs Classification · Target Variable

선택: 초기 100사이클 이내에서 제공된 총 수명 cycle_life를 회귀 예측합니다. 초기 ΔQ 신호를 활용할 수 있고, B1: 550 미만 1/46, 550 이상 45/46; B2: 550 미만 30/39, 550 이상 9/39; B3: 550 미만 1/44, 550 이상 43/44. Batch 1의 550 미만 표본 부족 때문에 5사이클 이전 분류는 검증 분할과 F1 추정이 매우 불안정합니다.

cycle_life는 총 수명이며 RUL 그 자체가 아닙니다. 관측 종료 100사이클에서의 잔여 수명을 별도로 표현한다면 동일 EOL 정의하에서 cycle_life-100과 연결하되, 미완주/라벨 정의 확인을 진행합니다.

선택 근거 · Q1과 연결

설명용 장·단수명 구분(>1,000 / <500)과 분류 후보 기준(550)은 목적이 다르다. B1의 550 미만 표본은 1/46개여서 분류 검증이 불안정하다. 총 수명을 연속값으로 예측하는 회귀를 선택하며, 입력 관측 기간은 초기 100사이클, Target Variable은 제공된 cycle_life(사이클)다.

모델 설계 전략 3. Modeling Strategy

후보 모델 · EDA 시사점과 선정 이유

1. 중앙값 기준 모델

EDA 근거: Q1: 소표본과 배치별 수명 분포 차이

선정 이유·검증: 학습 라벨 중앙값을 예측하는 기준을 두어 복잡한 모델의 개선 여부를 확인합니다.

2. Ridge / Elastic Net · 우선 후보

EDA 근거: Q3·Q5: ΔQ 로그 분산의 강한 관계와 ΔQ 통계 간 공선성

선정 이유·검증: 소수 피처를 표준화하고 규제로 중복 피처의 영향을 줄입니다. alpha와 l1_ratio는 B1 그룹 CV에서 제한된 범위로 비교합니다.

3. Random Forest / Extra Trees · 비교 후보

EDA 근거: Q4·Q5: 정책·온도·열화 신호의 관계가 배치별로 변함

선정 이유·검증: 비선형 관계·상호작용 가능성을 검증하는 후보이며, 그 존재가 입증됐다고 주장하지 않습니다. 깊이 2-4, min_samples_leaf 3-8부터 비교하고 과적합·외삽 한계를 확인합니다.

4. CatBoost · 보조 후보

EDA 근거: Q4: 정책 원문이 범주형이고 외부 배치에 미관측 정책이 존재

선정 이유·검증: 정책 수치 분해와 범주형 처리 방식의 차이를 비교합니다. B1이 소표본이므로 얇은 깊이·강한 규제를 사용하고 CV 근거가 있을 때 채택합니다.

후보별 제어 계획

후보	EDA 발견	선정 이유	검증/제어 계획
중앙값 기준 모델	셀 수가 적고 배치 분포 차이가 큼	학습 라벨 중앙값으로 기본 난이도 확인	튜닝 없음; 단순 예측을 넘어서는지 비교
Ridge / Elastic Net	ΔQ 통계와 초기 신호의 상관·중복 존재	표준화한 소수 피처, 규제로 분산 감소	alpha를 B1 그룹 CV에서 선택; Elastic Net l1_ratio도 제한된 후보
Random Forest / Extra Trees	정책 전환·온도·열화 신호 상호작용 가능	비선형 대안으로 선형 모델과 비교	깊이 2-4, min_samples_leaf 3-8 우선; 외삽과 소표본 과적합 확인
CatBoost (보조 후보)	정책 원문은 범주형이며 미관측 정책이 나타남	범주형 처리 대안; 수치 분해와 비교	깊이 2-4·강한 규제·작은 탐색; 초기 모델로 무조건 채택하지 않음

우선 순서: 데이터·라벨 정합성 → 중앙값 기준 → ΔQ 중심 소수 피처의 Ridge → 피처군 추가/제거 비교 → 비선형 후보. 모든 후보는 계획이며 최적 모델·성능은 확정하지 않았습니다. 로그 타깃도 B1 CV에서만 비교하고 역변환 후 원래 사이클 단위의 MAPE를 평가합니다.

데이터 처리 · 분할 · 평가 전략

분할 계획		셀 수	정책 그룹 수	최소 수명	최대 수명
Train for CV		36	18	636.000	1227.000
Valid hold-out		10	5	534.000	757.000

배치	미관측 정책 셀	총 셀	미관측 비율 (%)
B2	32	39	82.051
B3	44	44	100.000

구분	MAPE (%)	평가 계획 / 산식
Train (Batch 1 CV)	미측정	hold-out을 제외한 B1에서 GroupKFold 5-fold 평균 MAPE
Valid (Batch 1 Hold-out)	미측정	정책 그룹 단위 약 20%; seed=42; 재사용 튜닝 금지
Test (Batch 2)	미측정	라벨이 있는 B2 최종 평가; 튜닝에 사용하지 않음
Gap (Train-Valid)	미측정	Valid MAPE – Train CV MAPE (퍼센트포인트)
Gap (Valid-Test)	미측정	Test MAPE – Valid MAPE (퍼센트포인트)
Gap (Target-Test)	미측정	Test MAPE – 9.1% (퍼센트포인트); 양수=목표 대비 저하

분할: B1의 원문 정책 그룹을 정렬 후 seed=42로 섞어 약 20% 그룹을 hold-out으로 고정합니다. 나머지 그룹에서 5-fold GroupKFold로 후보를 비교합니다. 동일 셀·정책이 분할을 넘지 않으며 반복 측정 행 단위의 무작위 분할은 하지 않습니다. 라벨 정합성 확인으로 셀이 변경되면 동일 규칙으로 다시 고정하고 변경 로그를 남깁니다.

파이프라인: 학습 fold에서만 결측 대체 → 공선성 축소/피처 선택 → 스케일/인코딩 → 규제·모델 학습. 미관측 정책은 One-hot ignore 또는 모델의 미관측 범주 처리로 대응합니다. Train 지표는 재학습 적합 오차가 아니라 CV 평가 평균입니다.

분할 한계: 고정한 hold-out의 수명은 534–757사이클, CV 학습 부분은 636–1,227사이클입니다. 짧은 수명 정책이 hold-out에 몰려 있어 이 점수는 미관측 정책과 수명 분포 이동이 함께 작용한 결과로 해석해야 합니다. 데이터/라벨 확정 뒤 정책 그룹 단위의 반복 분할을 보조 평가로 검토하되 결과가 좋아지는 분할을 고르지 않습니다.

외부 평가: B2는 최종 테스트, B3는 선택적 추가 테스트입니다. 원문 정책의 미관측 비율은 위와 같아 분해 수치와 측정 신호의 일반화가 중요합니다. DAY 1에서 B2/B3를 탐색했으므로 완전히 보지 않은 테스트라고 주장할 수 없습니다. 성능 기반 튜닝은 B1에 제한합니다.

해석: $MAPE=100\times\text{mean}(|y-\hat{y}|/y)$. 요구사항의 비교 목표 9.1%는 참조 기준이며, 로컬 데이터와 원논문 배치·전처리·평가 구성 차이가 있어 직접 재현했다고 주장하지 않습니다. 전체 지표와 함께 수명 구간·정책·구조별 잔차와 가장 큰 오차 셀을 확인합니다.

부록 A. 데이터 구성·품질과 EOL 주의

배치	원본 셀	라벨 보유	라벨 결측	최소 기록	최대 기록	5사이클 확보	100사이클 확보	ΔQ 확보	QD 비정상 행	NaN 요약값
B1	46	46	0	533	1226	46	46	46	48	0
B2	47	39	8	101	1252	47	47	47	11	0
B3	46	44	2	540	2237	46	46	46	0	0

셀 ID	충전 정책	제외 사유
B2c22	VarCharge-2C-100cycles	cycle_life 결측; 수명 관련 분석에서 제외
B2c23	VarCharge-4C-100cycles	cycle_life 결측; 수명 관련 분석에서 제외
B2c35	VarCharge-6C-100cycles	cycle_life 결측; 수명 관련 분석에서 제외
B2c36	VarCharge-8C-100cycles	cycle_life 결측; 수명 관련 분석에서 제외
B2c37	3.6C(80%)-3.6C(SLOWCYCLE	cycle_life 결측; 수명 관련 분석에서 제외
B2c38	4.8C(80%)-4.8C(SLOWCYCLE	cycle_life 결측; 수명 관련 분석에서 제외
B2c39	3.6C(9%)-5C(SLOWCYCLE	cycle_life 결측; 수명 관련 분석에서 제외
B2c40	5.2C(58%)-4C(SLOWCYCLE	cycle_life 결측; 수명 관련 분석에서 제외
B3c23	4.8C(80%)-4.8C-newstructure	cycle_life 결측; 수명 관련 분석에서 제외
B3c32	4.8C(80%)-4.8C-newstructure	cycle_life 결측; 수명 관련 분석에서 제외

핵심: 원본 139개 중 수명 라벨이 있는 129개를 수명 관련 분석에 사용합니다. 누락 라벨은 추정·대치하지 않습니다. 용량의 비정상 행은 전체 곡선 표시·초기 피쳐 계산에서만 제외하고 원본을 보존합니다. 초기 기준 용량은 사이클 2~10의 양수 QD 중앙값이며, $QD \leq 0$ / 비유한값 / 초기 기준의 1.3배 초과를 비정상으로 표시합니다. 80% 이하 용량은 제거하지 않습니다.

자료 대응: 모든 셀에서 summary.cycle=1...N과 cycles 배열 길이가 일치합니다. 따라서 확인된 실제 cycle 위치로 10·100을 선택했습니다. Vdlin은 모든 셀에서 1,000포인트, 3.5→2.0V로 확인됐습니다. 문서 예시의 3.6V를 사용하지 않았습니다.

동일 물리 셀 확인의 한계: 배치 간 반복되는 barcode 직렬화 값은 46개이며 서로 다른 정책에도 재사용됩니다. 이 필드는 물리 셀 식별자로 신뢰할 수 없습니다. 원논문 로딩 코드는 이어서 측정된 셀의 결합·제외를 제공하지만, 로컬 Batch 2는 47셀 및 다른 정책 구성으로 원논문 예제와 대응하지 않습니다. 해당 인덱스 매핑을 적용하지 않았습니다. 동일 셀의 배치 간 중복이 없다는 보장은 확보하지 못했으므로 DAY 2 분할 전 실험 로그·실제 식별자 확인이 필요합니다.

EOL 주의: 수명 라벨이 있는 Batch 1·3 모든 셀의 기록 종료 비율은 초기 기준 용량 대비 80%보다 높고, Batch 2는 모두 아래입니다. cycle_life를 제공 라벨로 유지하되, 미완주·명목용량 기준·라벨 정의 차이를 확인해야 합니다. 종료 길이로 누락 라벨을 생성하거나 원논문 수명을 임의로 더하지 않았습니다.

부록 B. Batch 1·2·3 비교 요약

배치	라벨셀	수명중앙값	정책수	구조점미사비율	delta_logvar 중앙값	mean_Tavg 중앙값	mean_chargetime 중앙값
B1	46	858.500	23	0.000	-3.879	32.802	11.145
B2	39	472.000	12	23.077	-3.518	33.013	10.175
B3	44	1005.500	8	100.000	-4.196	34.112	10.043

B1과 B2의 수명 중앙값은 858.5 대 472사이클로 유사하지 않습니다. 이 로컬 파일에서는 요구사항의 일반적인 B1/B2 유사 분포 설명이 그대로 성립하지 않습니다. B3는 중앙값 1,005.5사이클이며 전 셀 정책에 newstructure가 있습니다.

평균 온도는 B3가 높는데 수명도 길어 배치가 섞인 온도 상관을 원인으로 해석할 수 없습니다. 정책·구조·측정 차이가 결합된 상황이므로 B1 내 신호로 전략을 설계하고, 외부 배치의 성능 저하는 타깃 분포·미관측 정책·센서 정합성별로 해석합니다. 표의 구조점미사 비율은 원문 표식의 비율(%)이며 실제 구조 사양을 검증한 값은 아닙니다.

부록 C. ESS 적용 범위와 남은 확인

활용: 초기 관측을 통해 배터리 셀의 총 수명 순위와 예상 수명을 추정하면 교체 계획, 셀 선별, 운영 조건 검토의 입력으로 활용할 수 있습니다. DAY 1 결과는 설계 근거이며 실제 운영 정확도나 비용 절감을 증명한 결과가 아닙니다.

제약: 실험 셀 데이터에서 팩·모듈 ESS로 이동하면 온도 관리, 실제 충방전 패턴, 제조 차이와 셀 간 상호작용이 추가됩니다. 로컬 Batch 2의 구조·정책 변화, 누락 타깃, Batch 1 종료 상태와 미확인 물리 셀 ID는 성능 비교의 주요 제한입니다.

우선 확인: ① 원본 출처·배치 대응과 cycle_life의 EOL 기준 ② Batch 1 일부 셀의 미완주·후속 측정 여부 ③ 실제 물리 셀 식별자·중복 ④ 온도·IR·충전시간의 측정 정의와 결측 코드 ⑤ raw 방전과 Qdlin 보간·시작 용량 차이. 확인 결과를 DAY 2 데이터 확정 기록에 남깁니다.

교정 사항: 셀 순서 색상을 수명 색상으로 해석하던 설명, 0.88x초기용량을 80%로 표기하던 기준선, IR 스파이크 원인·온도 인과 관계의 단정은 제거했습니다. 설명용 knee와 모델용 초기 피처를 분리했습니다.

부록 D. 참고자료와 재현 방법

제공 문서: 요구사항/요구사항 문서.md, 요구사항/추가적인_평가기준.md, 요구사항/sample.md, day1/day1.md.

데이터 안내: Kaggle · Data-driven prediction of battery cycle. 실제 분석은 로컬에 제공된 세 파일을 사용했습니다.

서지: Severson et al. (2019), Data-driven prediction of battery cycle life before capacity degradation, Nature Energy 4, 383–391. 성능 비교 수치 9.1%는 과제 요구사항에서 인용했습니다.

자료 구조·원논문 정제 절차 확인: 원논문 공개 저장소의 BuildPkl_Batch1 및 Load Data. 로컬 배치와 다르므로 해당 셀 인덱스 교정·제외 목록은 직접 적용하지 않았습니다. 확인일: 2026-10-01.